

# Sistema Inteligente de Consejería Académica

n.klopstock, s.martinez, eg.soto, d.fuquen

October 2025

## 1 Contexto de negocio

El proyecto propuesto está enfocado en consejerías universitarias. En ellas, los consejeros se encargan de orientar a los estudiantes en su planeación de su trayectoria académica, toma de decisiones sobre carga de cursos e identificación de estrategias para mejorar su rendimiento y bienestar académico. Hoy en día, muchas universidades enfrentan desafíos sobre las altas cantidades de estudiantes y sus diferentes y diversos perfiles académicos, lo que exige procesos de orientación más personalizados, ágiles y basados en evidencia.

En este contexto, la oficina de consejería académica de cada departamento de la universidad tiene un rol fundamental dentro del ecosistema educativo, con acceso a información valiosa sobre historiales académicos de estudiantes. Sin embargo, estos datos rara vez se usan de manera sistemática y analítica para apoyar la toma de decisiones o mejorar los procesos de orientación estudiantil.

### 1.1 Problemática

Como ya se mencionó anteriormente, los procesos actuales de consejería académica suelen estar sustentados principalmente por experiencias personales y criterio empírico de los consejeros. Estos basan sus recomendaciones en casos previos o en percepciones individuales, en muchos casos solo conociendo una parte de toda la información disponible del estudiante.

Es cierto que esta práctica ha funcionado históricamente, pero no garantiza consistencia ni objetividad en las orientaciones. Cada semestre, los consejeros deben atender a muchos estudiantes con diversos contextos y trayectorias, lo que dificulta las recomendaciones personalizadas y basadas en evidencia.

La falta de un sistema analítico que aproveche los mencionados datos históricos estudiantiles limita la capacidad de identificar patrones de éxito o riesgo para diferentes casos, y predecir posibles resultados que un estudiante podría alcanzar según sus condiciones.

La problemática tiene un alto impacto sobre la efectividad de la orientación y la planeación académica. Esto, además, puede tener por su parte efecto en aumentar las tasas de graduación semestrales, reducir la deserción, mejorar promedios académicos y optimizar el tiempo y cantidad de consultas privadas entre estudiante y consejero. Por último, dado el contexto de educación superior, el acompañamiento personalizado usando datos puede representar una ventaja competitiva y un fortalecimiento de la experiencia estudiantil.

Dada esta problemática, se propone incorporar una herramienta de ciencia de datos que permita transformar la asesoría académica en un proceso más objetivo, informado y sustentado por datos reales visibles.

### 1.2 Objetivos y métricas de evaluación

El proyecto propone el desarrollo de un sistema de agrupamiento construido a partir de datos históricos de desempeño estudiantil. Este sistema buscará identificar patrones comunes entre estudiantes con trayectorias similares (cursos

inscritos, en qué semestre, con qué promedio, secuencias de materias, etc.). Estos agrupamientos se usarán luego para predecir posibles cargas académicas futuras y apoyar a los consejeros con las recomendaciones.

Aunque luego se va a explicar a mayor profundidad, el enfoque analítico inicial contempla la aplicación de técnicas de análisis exploratorio de datos y modelos de aprendizaje no supervisado, que permitan segmentar a los estudiantes en grupos de comportamientos académicos comparables.

Las métricas de desempeño (KPIs) que se van a usar para evaluar la efectividad del sistema se dividen en dos: a corto y largo plazo.

A corto plazo:

- **Tiempo promedio de consejería:** reducción del tiempo necesario para cada sesión gracias al acceso a información analítica fundamentada.
- **Nivel de satisfacción del estudiante:** percepción de los estudiantes respecto a la utilidad, claridad y personalización de esta nueva implementación.

Y, a largo plazo:

- **Promedio ponderado acumulado:** cambio del promedio en el rendimiento académico de los estudiantes luego de esta nueva implementación.
- **Tasa de aprobación de cursos:** proporción de estudiantes que aprueban materias con alta tasa de reprobación dentro de cada grupo identificado.

## 2 Diseño del producto de datos

El producto de datos propuesto busca transformar el proceso de consejería académica universitaria en uno más fundamentado, eficiente y personalizado.

### 2.1 Potenciales usuarios y procesos actuales

Hay dos principales usuarios del producto de datos. El primero son los **consejeros académicos** de organizaciones estudiantiles de educación superior. Estos desempeñan un rol importante en el acompañamiento y orientación de los estudiantes durante su proceso estudiantil. Como ya se mencionó antes, actualmente una sesión de consejería se basa en la revisión manual de la carpeta del estudiante y las materias disponibles según el plan de estudios de la carrera en cuestión. Con esta información, el consejero hace recomendaciones que dependen en gran medida de su conocimientos personal del programa académico y su experiencia previa con otros estudiantes y casos similares. Luego, están los **estudiantes**. Estos son usuarios indirectos del sistema, ya que son quienes realmente se benefician de las recomendaciones fundamentadas y justificadas por datos. Para ellos, el producto promete una asesoría más confiable y personalizada que reduzca la duda sobre qué materias ver o cómo planificar el semestre.

El principal dolor identificado en el proceso actual es la naturaleza empírica y poco sistematizada del proceso de recomendación. Las decisiones se sustentan mayoritariamente en la intuición o experiencia individual del consejero, lo que puede derivar en inconsistencias entre diferentes consejeros y un uso ineficiente del tiempo durante las sesiones. Además, la falta de una base de datos analítica dificulta la detección de patrones de éxito o de riesgo académico, así como cualquier tipo de validación sobre el éxito del mismo. La oportunidad de mejora radica en integrar un sistema que proporcione fundamentos objetivos basados en datos históricos, permitiendo así justificar las recomendaciones con evidencia empírica y reducir significativamente el tiempo requerido para el análisis de cada caso.

Por supuesto, este producto no busca reemplazar a un humano consejero. Su objetivo se cumple, también, cuando se complementa con conocimiento humano. Es necesario proveer a los consejeros académicos con herramientas que les permiten tomar decisiones mucho más fundamentadas y con mayor seguridad.

## 2.2 Requerimientos

El producto debe ser capaz de recuperar automáticamente el historial académico completo de un estudiante mediante su código de identificación y, a partir de una carga académica propuesta para el próximo semestre, posicionarlo dentro de un grupo de referencia mediante un algoritmo de agrupamiento multinivel (multilayer clustering). El sistema proporcionará una predicción de desempeño esperado junto con un índice de confianza que refleja la certeza de la clasificación realizada, permitiendo al consejero tomar decisiones informadas sobre la viabilidad del plan académico propuesto.

Desde un punto de vista funcional, el sistema deberá cumplir con los siguientes requerimientos:

- El consejero ingresará el código del estudiante y el sistema cargará automáticamente su historial académico completo desde la base de datos institucional.
- El consejero definirá la carga académica propuesta para el próximo semestre y el modelo determinará el clúster de pertenencia más probable.
- El sistema calculará y presentará un índice de confianza que cuantifica la certeza de la agrupación, junto con predicciones de rendimiento esperado basadas en el comportamiento histórico del clúster identificado.
- Una aplicación web permitirá visualizar el perfil del estudiante, su clúster proyectado, el índice de confianza y las predicciones, además de explorar escenarios alternativos modificando la carga académica propuesta.
- El sistema almacenará las clasificaciones generadas y los resultados reales posteriores para validación y mejora continua del modelo.

## 2.3 Componentes analíticos y tecnológicos

El proyecto se compone de dos partes principales. En el **componente analítico**, se emplearán datos históricos de expedientes estudiantiles para identificar patrones mediante técnicas de análisis exploratorio y algoritmos de agrupamiento (clustering), con el fin de crear un modelo capaz de clasificar estudiantes en grupos de desempeño similares. En el **componente tecnológico**, este modelo se integrará en una aplicación web que permitirá ingresar los datos de un estudiante, procesarlos a través del modelo entrenado y mostrar su grupo de pertenencia junto con recomendaciones académicas personalizadas. El primer prototipo fue diseñado utilizando Figma y puede verse en el siguiente enlace: <https://www.figma.com/community/file/1563043270302634802>

## 3 Implicaciones Éticas

Aunque contamos con datos anonimizados, el análisis de datos académicos con técnicas de *machine learning* requiere tener en cuenta principios éticos y legales rigurosos. En particular, considerando nuestro contexto local en Colombia, la Constitución (Art. 15) y la Ley 1581 de 2012 —*Régimen General de Protección de Datos Personales*— protegen la privacidad e intimidad de los estudiantes. Como explica [y a Distancia (UNAD), 2025], esta ley exige que todo tratamiento de datos personales se realice con consentimiento previo, expreso e informado del titular y bajo principios rectores como legalidad, confidencialidad y acceso restringido.

En la práctica, la universidad ya cumplió con estos pasos y debió haber informado a los estudiantes para qué fines se usarán sus datos académicos y financieros, y sólo tratar la información necesaria. Esto puede comprobarse en la *Normatividad Interna de la Universidad de los Andes respecto al uso de datos personales* (<https://usodedatospersonales.uniandes.edu.co/es/normatividad/normatividad-interna>, <https://usodedatospersonales.uniandes.edu.co/es/>).

La Ley 1581 establece que el objetivo principal del tratamiento de datos es proteger los derechos fundamentales de las personas, especialmente la privacidad y la intimidad [y a Distancia (UNAD), 2025]. En este contexto, los datos académicos (calificaciones, materias cursadas, puntajes, historial) se consideran información sensible en el sentido de que reflejan el desempeño personal. Por ello, cualquier análisis —como *clustering* o modelos de aprendizaje automático— debe garantizar que los datos estudiantiles sean accesibles sólo por el personal autorizado y que su uso corresponda a los fines informados.

Como sugiere el *Archivo General de la Nación* en la *Guía de Anonimización de Datos Estructurados* (agn2021), incluso si los datos están anonimizados, se recomienda aplicar medidas adicionales contra la reidentificación (por ejemplo, agregación de datos o perturbación estadística) para reforzar la privacidad [Archivo General de la Nación, 2021].

Los registros académicos de los estudiantes (matrícula, calificaciones, etc.) son considerados datos privados. Según [ProtecData Latam, 2022], su divulgación indebida podría afectar la dignidad o el buen nombre de los alumnos. Por ello, tanto ética como legalmente, se impone el deber de confidencialidad: “no divulgar ni permitir que se divulgue lo que otras personas nos han confiado” ([FEVAS, 2023]). En la práctica, esto implica emplear controles de acceso adecuados, encriptación y protocolos de seguridad (claves, VPN, etc.) para proteger la base de datos. Sin embargo, dado que sólo contamos con una parte de la base de datos de la universidad, anonimizada y sin toda la información de cada estudiante, el riesgo es menor comparado con la base completa institucional.

Por otro lado, los modelos de *machine learning* (clustering, predicción de riesgo) pueden funcionar como cajas negras para los estudiantes y los consejeros. Como subraya la [UNESCO, 2021], es fundamental garantizar transparencia en cómo estos algoritmos toman decisiones. Se recomienda que los procesos automatizados sean comprensibles para estudiantes y consejeros. La falta de transparencia algorítmica puede generar sesgos en decisiones automatizadas [Área eLearning, 2024].

En consecuencia, es éticamente aconsejable documentar y explicar el funcionamiento del modelo (por ejemplo, qué factores influyen en la predicción de riesgo académico), e incluso considerar auditorías internas de los algoritmos. Esto incluye informar a los estudiantes sobre por qué un cierto perfil o grupo de riesgo fue asignado, de modo que puedan cuestionarlo o refutarlo si es necesario.

En conjunto, estas consideraciones éticas y normativas buscan que el uso de datos y técnicas analíticas en la consejería académica sea seguro, justo y beneficioso para los estudiantes. Todas las prácticas —desde la anonimización de datos hasta la explicación de los resultados— deben regirse por principios de protección de la privacidad, transparencia y equidad.

## 4 Enfoque Analítico

### 4.1 Hipótesis y preguntas de negocio

En primer lugar, se plantean las **hipótesis y preguntas de negocio** que guiarán la experimentación. Algunas hipótesis son:

- Existen segmentos claros de estudiantes con trayectorias académicas similares que permiten predecir riesgo de éxito o fracaso con suficiente antelación.
- Las recomendaciones basadas en el grupo al que pertenece un estudiante (por ejemplo, reducir carga, cambiar secuencia de materias o solicitar tutoría) disminuyen la probabilidad de baja académica en el siguiente

semestre.

- La automatización de recomendaciones permitirá dar recomendaciones con mayor fundamentos más allá de la experiencia y aprendizaje empírico del consejero.

A partir de estas hipótesis surgen las siguientes preguntas de negocio:

- ¿Qué características (promedios por materia, número de créditos, etc.) son más discriminantes para identificar qué tan probable o improbable es que un estudiante curse exitosamente su carga académica?
- ¿Qué proporción de estudiantes queda correctamente agrupada en segmentos accionables para la consejería académica?

## 4.2 Pipeline analítico propuesto

Para responder dichas preguntas se propone un **pipeline analítico** que combine análisis exploratorio de datos, técnicas de reducción de dimensionalidad, algoritmos de agrupamiento y modelos supervisados complementarios.

En la etapa de **análisis exploratorio de datos (EDA)**, se incluirán análisis univariados y bivariados, así como evaluación de la calidad de los datos y análisis y descubrimiento de variables claves.

## 4.3 Técnicas estadísticas y de aprendizaje automático

Para el desarrollo del modelo analítico se adoptará un enfoque fundamentado en los trabajos de [Clarke, 2008] y [Ochoa et al., 2016], que proponen estrategias para manejar estructuras jerárquicas y heterogeneidad entre grupos en contextos educativos. En el estudio de Clarke (2008), se discute de manera detallada cuándo la estructura de agrupamiento de los datos (por ejemplo, estudiantes anidados dentro de programas académicos) puede o no ser ignorada sin introducir sesgos significativos. Esta distinción es muy importante en entornos con datos escasos o distribuciones desbalanceadas entre grupos, donde un modelo de un solo nivel puede subestimar la varianza y sobreestimar los efectos individuales.

El proyecto considerará la naturaleza jerárquica de los datos académicos, integrando un modelo multinivel que capture la variabilidad tanto entre estudiantes como entre programas. Este enfoque permite representar de manera más realista la estructura de los datos y evitar errores de inferencia derivados de ignorar la dependencia entre observaciones. Además, siguiendo la propuesta de Ochoa (2016), se implementará un modelo de agrupamiento multinivel adaptativo que ajusta dinámicamente el nivel de granularidad del agrupamiento según la densidad y distribución de los datos. Este modelo resulta especialmente útil para predecir riesgo académico en contextos donde coexisten grupos de estudiantes con trayectorias homogéneas y otros con comportamientos atípicos o poco frecuentes.

## 4.4 Métricas de evaluación

Las métricas de evaluación del modelo se derivan directamente de las consideraciones metodológicas propuestas por Clarke (2008) y Ochoa (2016). Desde la perspectiva de Clarke, es esencial analizar el impacto de ignorar el nivel de agrupamiento, ya que un modelo de un solo nivel puede producir estimaciones sesgadas o sobreconfianza en los resultados, especialmente en contextos donde existen pocos estudiantes por grupo. Por tanto, se evaluará explícitamente la ganancia de ajuste y la reducción del error estándar al comparar un modelo multinivel frente a un modelo de un solo nivel. Esta comparación permitirá determinar la magnitud de la varianza explicada por el nivel grupal y cuantificar si el agrupamiento contribuye significativamente a la precisión de las predicciones.

Por otro lado, siguiendo la propuesta de Ochoa (2016), el modelo adaptativo será evaluado tanto por su capacidad para discriminar niveles de riesgo académico como por su estabilidad frente a conjuntos de datos con distinta densidad o composición. En este sentido, se analizará la homogeneidad interna de los grupos, la varianza entre niveles y la estabilidad de los agrupamientos mediante técnicas de bootstrapping o validación cruzada. En los componentes predictivos, se emplearán métricas clásicas de discriminación como el área bajo la curva ROC (AUC-ROC) y el área bajo la curva de precisión-recobrado (AUC-PR), así como medidas de calibración como el Brier score y las curvas de calibración.

## 5 Recolección de Datos

### 5.1 Descripción General de las Fuentes de Datos

El presente proyecto utiliza ocho datasets anonimizados provenientes del observatorio académico institucional. Todos los datos han sido procesados siguiendo un protocolo riguroso de anonimización que garantiza la protección de la identidad de los estudiantes mediante pseudonimización, generalización y supresión selectiva de información identificadora. Los identificadores directos han sido sustituidos por códigos alfanuméricos únicos que mantienen la consistencia relacional entre datasets.

#### 5.1.1 Historial Estados Estudiante

**Naturaleza temporal:** Histórico completo

**Granularidad:** Por estudiante y periodo académico

**Alcance:** Todos los periodos académicos registrados desde el ingreso del estudiante

Este dataset constituye la columna vertebral del análisis longitudinal, registrando la trayectoria académica completa de cada estudiante. Contiene 21 columnas que documentan el estado académico, programas matriculados, cambios de estado (suspensiones, pruebas académicas, reintegros), y métricas acumuladas de alertas académicas en cada periodo.

#### Características principales:

- Permite seguimiento temporal del estado académico de los estudiantes
- Incluye información de hasta dos programas simultáneos por estudiante
- Registra transiciones entre estados académicos con sus periodos correspondientes
- Documenta eventos críticos como suspensiones y pruebas académicas acumuladas

**Utilidad para el proyecto:** Esencial para poder entender el contexto del estudiante en la universidad hasta el momento.

#### 5.1.2 Historial Materias Estudiante

**Naturaleza temporal:** Histórico completo

**Granularidad:** Por estudiante, curso, periodo académico y nivel académico

**Alcance:** Registro completo de todas las materias cursadas

Dataset de máxima granularidad que registra cada materia inscrita por cada estudiante en cada periodo. Contiene 15 columnas con información sobre créditos, calificaciones, estado de la materia (aprobada, reprobada, retirada), y atributos específicos del curso. Los identificadores de estudiante y curso han sido pseudonimizados de

forma consistente.

**Características principales:**

- Nivel de detalle más fino disponible en el sistema
- Incluye calificaciones parciales y finales
- Registra diferentes modalidades de calificación y estados de materia
- Documenta sección, campus y atributos especiales de cada curso

**Utilidad para el proyecto:** En el contexto de las consejerías académicas es importantísimo poder entender en que materias el estudiante y en general los estudiantes de cierto perfil suelen tener problemas y que combinaciones de las mismas llevan a mejores resultados académicos (balanceo de la carga académica).

### 5.1.3 Historial Rendimiento Académico

**Naturaleza temporal:** Histórico completo

**Granularidad:** Por estudiante, periodo académico y nivel académico

**Alcance:** Métricas agregadas semestrales desde el ingreso

Dataset que consolida indicadores cuantitativos de desempeño académico por periodo. Contiene 22 columnas con métricas como PGA (Promedio General Acumulado), promedios semestrales, distribución de créditos por resultado (aprobados, reprobados, retirados, incompletos), y alertas específicas.

**Características principales:**

- Métricas acumuladas y por semestre para análisis comparativo
- Incluye indicadores de progreso curricular (porcentaje de créditos aprobados)
- Registra materias cursadas por tercera vez (alerta crítica)
- Documenta créditos homologados que afectan el avance curricular

**Utilidad para el proyecto:** Vista académica general de los estudiantes, esto permite entender mucho mejor el desempeño general del estudiante en un determinado semestre.

### 5.1.4 Información Actual Estudiante

**Naturaleza temporal:** Snapshot actual (último periodo disponible)

**Granularidad:** Por estudiante

**Alcance:** Estado más reciente de cada estudiante activo

Dataset transversal que captura el estado actual de los estudiantes. Contiene 30 columnas con información demográfica generalizada (edad, género codificado, estrato socioeconómico codificado), académica (programas, estado, penalizaciones), y de admisión (información de colegio pseudonimizada, puntajes ICFES descontextualizados).

**Características principales:**

- Variables demográficas protegidas mediante generalización

- Género Estrato socioeconómico codificado
- Puntajes ICFES específicos renombrados como ICFES\_CRITERIO\_1 a ICFES\_CRITERIO\_5
- Información de colegio con identificadores pseudonimizados (SCH\_XXXXXXX)

**Utilidad para el proyecto:** Si bien es importante entender a profundidad la dimensión académica del estudiante, también es necesario poder determinar que tanto afecta la dimensión social y económica del estudiante.

#### 5.1.5 Horarios Curso

**Naturaleza temporal:** Por periodo académico

**Granularidad:** Por periodo, curso (CRN) y franja horaria

**Alcance:** Programación académica completa por periodo

Dataset que documenta la programación de cada curso ofertado. Contiene 16 columnas con información de franjas horarias (inicio/fin de fecha y hora), días de la semana, ubicación (código de salón), y sección. Los identificadores CRN y CODIGO\_CURSO están pseudonimizados de forma consistente con el dataset de Historial Materias.

**Utilidad para el proyecto:** Puede llegar a ser importante y relevante en alguno de los de niveles de clusterización.

#### 5.1.6 Riesgos Estudiante Pregrado

**Naturaleza temporal:** Histórico completo

**Granularidad:** Por estudiante y periodo académico

**Alcance:** Indicadores binarios de riesgo por periodo

Dataset especializado para sistemas de alerta temprana. Contiene 12 columnas con indicadores binarios (0/1) que señalan la presencia de factores de riesgo académico predefinidos. Cada indicador representa una condición específica que la literatura identifica como predictor de deserción o bajo rendimiento.

##### **Características principales:**

- 10 indicadores de riesgo independientes calculados algorítmicamente
- Valores binarios facilitan modelado de machine learning
- Incluye riesgos de corto plazo (semestre actual) y acumulativos
- Cubre múltiples dimensiones: rendimiento, retiros, progreso curricular

##### **Indicadores incluidos:**

- Tres o más materias parcialmente perdidas
- Tres o más materias retiradas
- Bajo promedio en segundo semestre
- Bajo promedio desde tercer semestre en adelante
- Bajo promedio móvil



- Pocos créditos inscritos respecto a matrícula pagada
- Materias bloqueantes no aprobadas
- Semestres perdidos con estado académico normal
- No aprobación de lectura/inglés al sexto semestre
- Porcentaje de créditos aprobados menor al 50%

**Utilidad para el proyecto:** En las consejerías académicas es fundamental poder conocer los riesgos que tuvo el estudiante en el momento de tomar cierta carga académica.

#### 5.1.7 Información Financiera Estudiante

**Naturaleza temporal:** Histórico completo

**Granularidad:** Por estudiante, periodo y tipo de financiamiento

**Alcance:** Registro de todos los tipos de financiamiento aplicados

Dataset que documenta las modalidades de financiamiento de la matrícula de cada estudiante. Contiene 12 columnas con información sobre tipos de financiamiento (becas, créditos, descuentos), fechas de aplicación, porcentajes de aporte, y clasificación principal del financiamiento por semestre.

##### Características principales:

- Múltiples registros por estudiante-periodo (diferentes tipos de financiamiento)
- Variable de ranking para identificar financiamiento principal
- Diferenciación entre financiamiento principal y parcial
- Clasificación jerárquica en tipos específicos, principales y generales

**Utilidad para el proyecto:** Fundamental para análisis de equidad financiera y su relación con permanencia y éxito académico.

#### 5.1.8 Percentiles Académicos Estudiante

**Naturaleza temporal:** Histórico completo

**Granularidad:** Por estudiante, periodo y programa académico

**Alcance:** Ubicación percentil dentro de cada programa

Dataset que proporciona contexto de rendimiento relativo. Contiene 11 columnas que ubican a cada estudiante dentro de la distribución de rendimiento de su programa académico, incluyendo percentil de PGA, clasificación por tipo de estudiante, y agrupación por avance semestral.

##### Características principales:

- Percentiles calculados por programa específico (comparación intra-programa)
- Clasificación de estudiantes por características (Estudiante activo o graduado)
- Agrupación por semestre de avance para comparaciones justas

- Permite análisis longitudinal de posición relativa

**Utilidad para el proyecto:** Esencial para análisis comparativo que considera el contexto específico de cada programa. Permite identificar estudiantes en riesgo relativo a su grupo de pares, independientemente de las diferencias de dificultad entre programas.

## 5.2 Referencias al Diccionario de Datos

Las descripciones detalladas de cada columna, sus tipos de datos, y valores únicos (donde aplique) se encuentran documentadas en el **Anexo A: Diccionario de Datos Anonimizados**. El diccionario incluye:

- Nombre de la columna
- Tipo de dato
- Descripción funcional

## 6 Entendimiento de los datos

Debido a la cantidad de fuentes de datos, así como el alto número de columnas, se decidió generar un informe únicamente orientado al entendimiento de los datos. El cual se adjunta dentro de la entrega. Adicionalmente. Todo el procesamiento en código junto con las imágenes se encuentra en el repositorio en cuadernos de Jupyter.

## 7 Preparación de datos

El proceso de preparación de datos del sistema LADA (Learning Analytics Dashboard for Academic Advising) se estructuró en múltiples etapas de transformación, limpieza, validación e ingeniería de características, iniciando con la carga de cinco conjuntos de datos en formato Parquet: historial de materias, rendimiento académico, percentiles académicos, información actual de estudiantes y riesgos históricos. Cada uno de estos conjuntos fue sometido a procesos específicos de validación para garantizar la consistencia, completitud y calidad de los datos de entrada.

La primera fase de transformación se enfocó en la limpieza del historial de materias cursadas. Se aplicaron filtros estrictos para conservar únicamente registros de estudiantes de pregrado con historial académico completo, excluyendo registros incompletos o en estado “en progreso”. Los resultados académicos fueron estandarizados en tres categorías válidas: APROBADO, REPROBADO y RETIRADO. A partir de esta clasificación se construyó una variable binaria denominada `EXIT0`, donde APROBADO se codifica como 1 y cualquier otro resultado como 0. Esta representación binaria permite posteriormente el cálculo de tasas de éxito mediante operaciones de agregación simples.

El tratamiento de valores faltantes se abordó mediante estrategias diferenciadas según la naturaleza de cada variable. Para el rendimiento académico histórico (PGA), se estableció un esquema de múltiples fuentes: cuando un estudiante no cuenta con PGA previo, se utiliza su puntaje ICFES normalizado a una escala 0–5 mediante la transformación  $(PUNTAJE\_ICFES/500) \times 5$ . En los casos en los que no se dispone ni de PGA ni de ICFES, el registro es excluido del análisis. Para variables asociadas a percentiles y riesgos académicos, los valores nulos se conservaron o se imputaron con cero dependiendo de su interpretación semántica.

La fase de ingeniería de características constituyó un componente crítico del preprocesamiento. Se diseñó un sistema jerárquico de representación de combinaciones de cursos con tres niveles de especificidad. El `NIVEL_1` utiliza únicamente el número total de cursos como firma del período. El `NIVEL_2` agrupa los cursos por categoría temática,

extraída de los primeros tres dígitos del código de cada asignatura. Finalmente, el `NIVEL_3` emplea los códigos exactos de los cursos ordenados alfabéticamente. Esta jerarquía permite realizar una selección adaptativa según la disponibilidad de datos históricos, balanceando cobertura y especificidad.

Una transformación fundamental fue el cálculo de variables históricas del período anterior, particularmente `PGA_ANTERIOR`. Para ello se utilizó la técnica `merge_asof` con dirección *backward* y exclusión de coincidencias exactas, garantizando que cada registro utilice exclusivamente información correspondiente al período académico inmediatamente anterior. Este mecanismo evita completamente el *data leakage* temporal y asegura la validez del entrenamiento. De manera complementaria se calcularon las variables `SEMESTRES_ANTERIORES`, que representa la experiencia académica acumulada, y `PCT_CREDITOS_ANTERIOR`, que caracteriza el historial de aprobación del estudiante.

Posteriormente, se realizó un proceso de agregación temporal para transformar los datos desde el nivel de materia individual hasta el nivel de semestre. Para cada combinación estudiante-período se generaron las siguientes variables: lista de cursos inscritos (`CURSOS_LISTA`), suma total de créditos (`CREDITOS_TOTALES`), cantidad de cursos (`NUM_CURSOS`) y tasa de éxito del semestre (`TASA_EXITO`), definida como el promedio de la variable binaria `EXITO`.

Las variables continuas fueron normalizadas mediante el uso de `StandardScaler` de *scikit-learn*, aplicando la transformación z-score a las variables `PGA_ANTERIOR`, `SEMESTRES_ANTERIORES`, `PCT_CREDITOS_ANTERIOR`, `NUM_CURSOS` y `CREDITOS_TOTALES`. El escalador fue entrenado exclusivamente sobre el conjunto de entrenamiento y aplicado posteriormente a validación y prueba sin recalcular estadísticas, previniendo filtraciones de información.

Finalmente, se implementó un proceso automático de validación de integridad temporal que verifica que todos los registros con `PGA` histórico correspondan efectivamente a períodos anteriores al período de análisis. Este mecanismo garantiza la coherencia del enfoque temporal y asegura la validez del pipeline completo, el cual procesó aproximadamente 285 000 registros de inscripciones semestrales y generó un dataset final con 11 características principales y tres niveles de representación jerárquica.

## 8 Estrategia de validación y selección de modelo

La estrategia de validación del sistema LADA se fundamenta en un esquema de separación temporal estricta, reconociendo que los datos académicos poseen una estructura secuencial donde los períodos futuros no deben influir en predicciones de períodos pasados. En este contexto se definieron tres conjuntos disjuntos mediante cortes temporales específicos: entrenamiento (`TRAIN`), validación (`VALIDATION`) y prueba (`TEST`).

El conjunto de entrenamiento comprende los períodos menores o iguales a 202010 y se utiliza exclusivamente para la construcción de clústeres mediante Fuzzy C-means y el cálculo de probabilidades de éxito por grupo. Este conjunto contiene aproximadamente 180 000 registros de inscripciones semestrales y proporciona la base empírica para la identificación de patrones académicos históricos.

El conjunto de validación corresponde al intervalo comprendido entre 202010 y 202310. Este conjunto se emplea para evaluar el comportamiento del modelo en datos no observados durante el entrenamiento y para la selección de hiperparámetros. La validación temporal permite simular un escenario de predicción prospectiva, reflejando de forma más realista el desempeño esperado en producción.

El conjunto de prueba contiene los períodos posteriores a 202310 y representa aproximadamente 40 000 registros. Este conjunto se reserva exclusivamente para la evaluación final del modelo seleccionado, simulando de manera fiel el entorno real de despliegue del sistema. Sobre este conjunto se calculan métricas como MAE, RMSE, correlación y exactitud dentro de una ventana de tolerancia del 10%.

Se verificó estadísticamente que la distribución de la variable objetivo `TASA_EXITO` se conserva entre los tres subconjuntos. El conjunto de entrenamiento presenta una media de 0.874 con desviación estándar de 0.203, mientras que los conjuntos de validación y prueba presentan medias de 0.881 y 0.885 respectivamente, con desviaciones

Table 1: Comparación de métricas de evaluación entre algoritmos de clustering

| Algoritmo     | MAE Mean      | MAE Std       | Silhouette Mean | Silhouette Std | Davies-Bouldin Mean |
|---------------|---------------|---------------|-----------------|----------------|---------------------|
| Fuzzy C-means | 0.0679        | 0.0490        | 0.3900          | 0.0762         | 1.0616              |
| GMM           | <b>0.0675</b> | <b>0.0463</b> | 0.2948          | 0.1514         | 1.5107              |
| K-means       | 0.0680        | 0.0490        | <b>0.3924</b>   | 0.0752         | <b>1.0561</b>       |

similares. Esta consistencia fue confirmada mediante la prueba de Kolmogorov-Smirnov, evidenciando que la partición temporal no introduce sesgos distribucionales relevantes.

De igual forma, las distribuciones de las variables predictoras principales se mantienen estables entre los tres conjuntos. El `PGA_ANTERIOR`, el número de cursos y el total de créditos conservan medias y varianzas similares, lo que valida la coherencia estadística del proceso de partición.

## 9 Construcción y evaluación del modelo

El proceso de construcción del modelo incluyó la experimentación con múltiples algoritmos de *clustering*, entre ellos Fuzzy C-means, K-means y Gaussian Mixture Models, evaluando distintas configuraciones de hiperparámetros como el número de clústeres, coeficientes de fuzzificación y criterios de convergencia. Cada modelo fue entrenado utilizando exclusivamente el conjunto TRAIN.

La evaluación cuantitativa se realizó sobre el conjunto VALIDATION utilizando como métrica principal el Mean Absolute Percentage Error (MAPE) calculado sobre la predicción de la `TASA_EXITO`. Adicionalmente, se incorporaron métricas complementarias de cobertura para penalizar configuraciones que generaran un número elevado de casos sin predicción válida.

El modelo Fuzzy C-means demostró superioridad frente a K-means y Gaussian Mixture Models al presentar el menor MAPE promedio y una mayor estabilidad en la asignación de probabilidades, especialmente en los niveles jerárquicos de representación. Su capacidad de pertenencia difusa permite capturar de forma más realista la naturaleza continua del rendimiento académico.

Ahora bien, al ver 1 es posible identificar varios aspectos importantes sobre las métricas:

Desde una perspectiva cualitativa, el modelo seleccionado se destacó por generar clústeres interpretables, con diferenciación clara entre perfiles de alto, medio y bajo rendimiento. Entre las oportunidades de mejora identificadas se encuentran la incorporación de variables socioeconómicas, el análisis de trayectorias longitudinales más extensas y la integración de señales tempranas de riesgo académico.

Desde una perspectiva estrictamente cuantitativa, el modelo **Gaussian Mixture Model (GMM)** presenta el menor error promedio (MAE), lo cual indica una ligera superioridad en precisión respecto a Fuzzy C-means y K-means. No obstante, esta diferencia es marginal frente al comportamiento global de los modelos.

En términos de separación estructural de los clústeres, **K-means y Fuzzy C-means** presentan mejores valores de *silhouette* y *Davies-Bouldin*, lo que sugiere una mayor coherencia interna y separación entre grupos.

A pesar de que GMM obtiene el mejor MAE, su **costo computacional es significativamente mayor**, especialmente en los niveles jerárquicos más altos de la representación, lo que afecta su viabilidad para una aplicación interactiva. Por esta razón, y considerando los requerimientos de eficiencia, escalabilidad y estabilidad, **se selecciona Fuzzy C-means como el modelo final**, ya que ofrece un equilibrio adecuado entre precisión, interpretabilidad y velocidad de ejecución.

Adicionalmente, el carácter difuso de Fuzzy C-means permite modelar de forma más realista la transición continua entre distintos niveles de rendimiento académico, lo cual es consistente con la naturaleza no discreta del comportamiento estudiantil.

## 10 Construcción del producto de datos

### 10.1 Modelo

A partir del proceso de ideación y del modelo seleccionado, se desarrolló un prototipo funcional del sistema LADA. Este prototipo integra el modelo de clustering Fuzzy C-means, una API REST para la consulta de predicciones y una aplicación web orientada a usuarios institucionales.

El sistema permite ingresar el identificador de un estudiante y una configuración de cursos hipotética, y retorna como resultado la probabilidad estimada de éxito académico, junto con información explicativa asociada al clúster asignado, niveles de análisis, confianza del modelo y características agregadas del grupo de referencia.

La arquitectura del producto contempla un backend encargado del procesamiento de datos, inferencia del modelo y manejo de la lógica de negocio, un frontend desarrollado como dashboard interactivo para la visualización de resultados, y un mecanismo de despliegue sobre infraestructura local de la institución. Esta arquitectura permite desacoplar los componentes, facilitando escalabilidad, mantenimiento y posibles integraciones futuras.

El sistema fue validado cualitativamente por miembros de la organización, quienes confirmaron su utilidad como herramienta de apoyo a la toma de decisiones académicas, particularmente en contextos de planeación de carga, consejería y acompañamiento estudiantil.

### 10.2 Aplicación

A partir del modelo desarrollado y de la arquitectura propuesta, se implementó un módulo interactivo que permite a los consejeros ingresar el código del estudiante y construir una posible carga académica para el siguiente semestre, controlando además un límite máximo de créditos editable según el caso.

Una vez definida la lista de materias, el sistema recupera automáticamente el historial académico del estudiante, integra la nueva carga propuesta y ejecuta la predicción en tiempo real utilizando su contexto histórico. El resultado presentado incluye el porcentaje estimado de éxito académico para dicha combinación de cursos, acompañado de indicadores explicativos derivados del modelo y visualizaciones detalladas basadas en el grupo de referencia asignado. En particular, se muestran las distribuciones del clúster al que fue clasificado el estudiante, incluyendo variables como GPA histórico, número total de semestres cursados y porcentaje de créditos aprobados, destacando en cada gráfica la posición específica del estudiante frente a su cohorte comparable. Este componente facilita una interpretación intuitiva del riesgo y del rendimiento esperado, fortaleciendo la toma de decisiones informadas durante la sesión de consejería.

#### 10.2.1 Despliegue

En el estado AS-IS, el prototipo funciona de forma local, pero sí existe una separación entre el componente de predicción (que incluye todo el trato de los datos) y la interfaz del usuario. El modelo está dentro de una API REST que permite, una vez desplegado, acceder a las predicciones. En el estado TO-BE, se plantea una arquitectura modular basada en un servicio *stateless serving*, donde se va a incluir la API REST mencionada anteriormente, permitiendo realizar predicciones *online* durante la sesión de consejería académica. La API recupera el historial académico del estudiante y hará la clasificación en tiempo real, retornando las variables relevantes para mostrar en la interfaz del usuario. El despliegue se hará en contenedores Docker para garantizar portabilidad y consistencia. Finalmente, la arquitectura incluye un mecanismo de monitoreo de *data-* y *concept drift*. Este se basa en tres elementos centrales. Primero, se tendrá un seguimiento periódico de métricas clave asociadas al desempeño del sistema, como la consistencia de las predicciones generadas. Segundo, se entrenará un *mini-modelo* auxiliar utilizando solamente datos de los últimos dos años, con el fin de evaluar si el comportamiento reciente cambia de manera significativa en comparación al histórico. La idea es, si este modelo reducido comienza a sacar métricas de




Figure 1: Diagrama de despliegue

rendimiento significativamente distintas, se interpreta como un indicador temprano de drift. Finalmente, cuando se detecten cambios seguidos de métricas, se activará un protocolo de revisión del modelo principal y de los datos utilizados para su entrenamiento. Esto permite reevaluar diferentes aspectos del desarrollo del modelo que pueden ya no ser válidas por un cambio muy grande en el concepto del problema o de los datos recibidos.

## 11 Bitácora con el negocio

Esta sección presenta, en formato de bitácora, un resumen detallado de las principales interacciones sostenidas con la organización a lo largo del desarrollo del proyecto. En cada una de ellas se documentan los acuerdos establecidos en torno a la definición de la problemática u oportunidad, el acceso y tratamiento de los datos, el enfoque analítico adoptado y la validación progresiva de los resultados.

### 11.1 Primera interacción: Presentación del proyecto y definición del alcance

El primer acercamiento formal se realizó con la unidad de ingeniería, con el objetivo de presentar la propuesta general del proyecto y explorar su viabilidad dentro del contexto institucional. En esta instancia se plantearon dos posibles enfoques de trabajo: uno orientado al uso de técnicas de *clustering* como apoyo a la consejería académica, y otro enfocado en la deserción estudiantil y la predicción de éxito académico.

Tras evaluar ambas alternativas, la organización manifestó su disposición de facilitar el acceso a los datos, siempre y cuando se cumplieran estrictas condiciones de confidencialidad. En particular, se estableció que toda la información debía ser entregada de manera completamente anonimizada y que se elegía el enfoque de las consejerías académicas. Como resultado, se acordó que todos los atributos que pudieran representar un riesgo de identificación debían ser ocultados o codificados.

Este primer encuentro permitió definir el marco de trabajo inicial del proyecto, estableciendo desde el inicio una orientación hacia el análisis basado en patrones y agrupamientos, bajo un enfoque responsable de uso de los datos.

## 11.2 Segunda interacción: Acuerdo sobre anonimización y definición del enfoque analítico

En una segunda reunión se profundizó en los aspectos técnicos relacionados con el tratamiento de la información. Se acordó que el proceso de anonimización no se limitaría únicamente a los estudiantes, sino que también debía aplicarse a los cursos, programas y a diversos campos institucionales como nombres de asignaturas y códigos administrativos. El objetivo principal fue garantizar que el modelo pudiera capturar patrones relevantes sin comprometer la confidencialidad de las personas ni de las unidades académicas.

Adicionalmente, se estableció que la organización conservaría la facultad de realizar procesos de desanonimización de manera interna, únicamente con fines de análisis detallado de los hallazgos obtenidos. Este acuerdo permitió avanzar con tranquilidad en la fase de modelamiento, manteniendo siempre el control de la información sensible dentro de la institución.

En esta misma sesión se definió de manera formal el enfoque analítico que guiaría el proyecto: un sistema de *clustering multicapa*, capaz de analizar a los estudiantes desde distintos niveles de agregación. Este diseño permitiría no solo asignar grupos, sino también ofrecer distintas lecturas del comportamiento académico según la profundidad del análisis requerida.

## 11.3 Tercera interacción: Presentación del primer prototipo funcional

The screenshot shows a web browser window with the title 'Predictor Académico'. The address bar shows 'localhost:3000'. The main heading is 'Predictor académico' in blue, with a subtitle 'Ingrese códigos exactos para búsqueda rápida'. Below this is a form titled 'Configuración de predicción'. The form has two sections: '1. Seleccionar estudiante (pasar a selector)' with a text input containing 'Ej: EST\_00054523' and a 'Buscar' button; and '2. Agregar cursos a inscribir' with a text input containing 'Ej: CRS\_00017889' and an 'Agregar' button. Below the second section, it says 'No hay cursos agregados aún.' and '0 / 20 cursos'. At the bottom right of the form is a blue button labeled 'Analizar datos →'. A small circular icon with the letter 'N' is visible in the bottom left corner of the browser window.

Figure 2: Vista principal de primer prototipo

Posteriormente, se realizó una tercera reunión enfocada en la presentación de un primer prototipo funcional del sistema. Esta versión inicial consistía en una interfaz básica que permitía ingresar el código de un estudiante,




Figure 3: Vista de predicción

agregar los códigos de los cursos a analizar y, a partir de esta información, consultar el modelo para obtener la asignación a un clúster.

Durante esta sesión, la organización realizó observaciones clave relacionadas principalmente con la interpretación de los resultados. Se identificó, por ejemplo, que el clúster asignado se mostraba únicamente mediante un identificador numérico, lo cual no aportaba un significado comprensible para los usuarios finales. Asimismo, se evidenció que conceptos como “estudiantes similares” y “casos similares” no estaban claramente diferenciados en la interfaz, y que el campo correspondiente al nivel de análisis, presentado como **Nivel 2**, carecía de una explicación que permitiera entender su alcance.

Desde el punto de vista funcional, también se señaló que la restricción sobre la cantidad de cursos no debía hacerse por número de asignaturas, sino por cantidad de créditos, dado que limitar por cursos podría dar lugar a configuraciones académicas irreales dentro del contexto institucional.

Adicionalmente, la organización sugirió que el sistema debía ofrecer mayor información descriptiva sobre cada clúster, incorporando variables agregadas que permitieran comprender mejor el comportamiento académico del grupo al que se asigna cada estudiante. Entre estas variables se destacaron el porcentaje de créditos aprobados, el número de semestres cursados y la distribución del PGA dentro del grupo.

#### 11.4 Cuarta interacción: Validación de la propuesta ajustada de visualización y explicabilidad

A partir de todas las observaciones recibidas, se desarrolló una nueva versión del sistema en la que se realizaron cambios significativos tanto en la interfaz como en el tipo de información presentada. Esta versión incorporó elementos de explicabilidad, gráficas descriptivas de los clústeres, una definición clara de los niveles de análisis y un indicador explícito de la confianza del modelo.



La propuesta ajustada fue nuevamente presentada a un representante de la organización, quien validó positivamente la claridad de la visualización y la utilidad del sistema como herramienta de apoyo a la toma de decisiones. Se destacó que, gracias a los cambios realizados, ahora era posible no solo conocer la probabilidad de éxito académico estimada por el modelo, sino también comprender el contexto en el que dicha predicción se produce.

Finalmente, se dejó previsto un último espacio de socialización con un grupo ampliado de la organización, posterior a la entrega de esta fase del proyecto, con el propósito de presentar los resultados finales, discutir los hallazgos más relevantes y evaluar posibles escenarios de implementación futura.

## 12 Conclusiones

El proyecto cumplió con los objetivos propuestos, demostrando la viabilidad técnica y conceptual de un sistema inteligente de apoyo a la consejería académica de la Universidad de Los Andes basado en agrupamiento multinivel. Este avance representa un cambio claro desde un proceso actualmente empírico hacia uno que usa evidencia histórica y algoritmos lógicos que dan mayor validez a razonamientos.

Durante el desarrollo hubo varias dificultades a resaltar. La primera fue la necesidad de anonimizar los datos: dado que la información utilizada correspondía a estudiantes reales, no resultaba responsable emplearla sin un tratamiento previo que garantizara la protección de la identidad. Por esta razón, se implementaron múltiples técnicas de transformación y codificación tanto para estudiantes como para materias, asegurando la conservación de las relaciones estructurales sin exponer información sensible.

Segundo, y quizá el reto técnico más importante, la implementación de la estructura del modelo presentó múltiples dificultades. La complejidad de la arquitectura multicapa, junto con la necesidad de evitar completamente el uso de información futura durante el entrenamiento, obligó a diseñar cuidadosamente los procesos de agregación temporal, generación de variables históricas y validaciones automáticas de integridad temporal para prevenir *data leakage*.

Adicionalmente, el tratamiento de valores faltantes representó un desafío relevante, pues fue necesario combinar múltiples fuentes de información académica, como PGA e ICFES, para preservar la mayor cantidad posible de registros útiles sin introducir sesgos. Finalmente, la construcción de características jerárquicas para representar la carga académica implicó un balance constante entre nivel de detalle y cobertura de datos históricos, lo cual influyó directamente en la estabilidad del modelo y en su capacidad de generalización.

En relación al impacto sobre los KPIs mencionados durante el desarrollo del proyecto, se proyectan beneficios a corto y largo plazo. Por un lado, se anticipa una reducción del tiempo promedio de consejería entre un 25% y 30%, dado que los consejeros tendrían acceso inmediato a la predicción de agrupamiento y la decisión de recomendación puede empezar desde ahí durante la sesión. De manera complementaria, la satisfacción del estudiante podría aumentar entre 5% y 12% que se puede ver reflejado en encuestas posteriores a la sesión, debido a las recomendaciones más personalizadas y justificadas. Además, a largo plazo, se espera que el sistema contribuya a un aumento del 3% al 5% en el promedio ponderado acumulado de los estudiantes que usaron la herramienta durante la sesión de consejería un semestre tras otro. Del mismo modo, un aumento similar se proyecta para la tasa de aprobación de cursos con alta reprobación, al sugerir combinaciones de materias más coherentes con trayectorias históricas exitosas dentro de cada clúster. Por último, se espera una reducción de tasa de deserción en un 10%. Por supuesto, estas cifras son estimaciones y deben validarse usando algún piloto institucional que dure un par de semestres, para tener una muestra de resultados completa.

Para alcanzar mejores resultados que los obtenidos en este proyecto, se buscaría un dataset con datos más extensos y menos sesgados. Por el lado del modelo, este mismo puede implementarse de forma más completa y robusta; integrando mayor cantidad de atributos que se tendrán en cuenta durante el agrupamiento.

Finalmente, aún cuando el mejor modelo obtenido es suficiente para dar una solución inicial y sólida a la problemática propuesta, no debe interpretarse como la iteración final del mismo. El modelo actual funciona como una base avanzada y estable para un piloto, pero su rendimiento a largo plazo va a depender del proceso de monitorio continuo y la retroalimentación de los consejeros. Con estas iteraciones, el sistema tiene el potencial de convertirse en una herramienta institucional robusta capaz de transformar estructuralmente el proceso de consejería académica en la Universidad de Los Andes.

## References

[Archivo General de la Nación, 2021] Archivo General de la Nación (2021). Guía de anonimización de datos

- estructurados. [https://www.archivogeneral.gov.co/sites/default/files/Estructura\\_Web/5\\_Consulte/Recursos/Publicacionees/Guia\\_de\\_Anonimizacion-min.pdf](https://www.archivogeneral.gov.co/sites/default/files/Estructura_Web/5_Consulte/Recursos/Publicacionees/Guia_de_Anonimizacion-min.pdf). Ministerio de Cultura.
- [Clarke, 2008] Clarke, P. (2008). When can group level clustering be ignored? multilevel models versus single-level models with sparse data. *Journal of Epidemiology and Community Health*, 62(8):752–758.
- [FEVAS, 2023] FEVAS (2023). Guía: La confidencialidad en el ámbito educativo. <https://fevas.org/wp-content/uploads/2023/04/GUIA-LA-CONFIDENCIALIAD-EN-EL-AMBITO-EDUCATIVO.pdf>.
- [Ochoa et al., 2016] Ochoa, X., Méndez, G., Chiluiza, K., and Luzardo, G. (2016). Adaptive multilevel clustering model for the prediction of academic risk. In *Proceedings of the 6th International Conference on Learning Analytics & Knowledge (LAK '16)*, pages 237–241, Edinburgh, United Kingdom. ACM.
- [ProtecData Latam, 2022] ProtecData Latam (2022). Concepto sector educación sobre tratamiento de datos personales. <https://protecdatalatam.com/wp-content/uploads/2022/03/CONCEPTO-SECTOR-EDUCACION.pdf>.
- [UNESCO, 2021] UNESCO (2021). El uso ético de la inteligencia artificial en la educación. <https://unac.edu.mx/blog-2/el-uso-etico-de-la-inteligencia-artificial-en-la-educacion/>. Universidad de las Américas y el Caribe.
- [y a Distancia (UNAD), 2025] y a Distancia (UNAD), U. N. A. (2025). Lo que debes saber sobre el tratamiento y protección de datos personales. <https://noticias.unad.edu.co/index.php/2025/7277-lo-que-debes-saber-sobre-el-tratamiento-y-proteccion-de-datos-personales>. Noticias UNAD.
- [Área eLearning, 2024] Área eLearning (2024). Ética y sesgos en ia educativa: retos y soluciones. <https://areaelearning.com/etica-y-sesgos-en-ia-educativa-retos-y-soluciones/>.

## A Diccionario de Datos Anonimizados

Este anexo presenta las descripciones detalladas de todas las columnas presentes en los datasets anonimizados utilizados en el proyecto. Para cada variable se indica:

- **Nombre de la columna:** Nombre final después de la anonimización
- **Tipo de dato:** Tipo de dato original en el sistema fuente
- **Descripción:** Explicación funcional de la variable

### A.1 Dataset 1: Historial Estados Estudiante

Table 2: Variables del Dataset: Historial Estados Estudiante

| Columna                    | Tipo    | Descripción                                                                                           |
|----------------------------|---------|-------------------------------------------------------------------------------------------------------|
| CODIGO_ESTUDIANTE          | Int64   | Código estudiantil del estudiante. Todos los valores en esta columna tienen el formato: EST_XXXXXXX.  |
| PERIODO                    | Int64   | Periodo académico como número de 6 dígitos (YYYYPP: año + periodo).                                   |
| SEMESTRE_SEGUN_CREDITOS    | Decimal | Semestre según créditos aprobados dividido entre 17 créditos esperados.                               |
| MATRICULADO_PERIODO_ACTUAL | String  | Indica si un estudiante se encuentra matriculado en cada periodo académico. Valores posibles: NO, SI. |
| ESTADO_ACADEMICO           | String  | Estado académico del estudiante periodo a periodo. Existen 26 estados posibles.                       |
| CODIGO_PROGRAMA_1          | String  | Código del primer programa del estudiante.                                                            |
| PROGRAMA_1                 | String  | Nombre del primer programa del estudiante.                                                            |
| NIVEL_PROGRAMA_1           | String  | Nivel académico del primer programa. Valores posibles: Pregrado, Magíster, etc.                       |
| CODIGO_PROGRAMA_2          | String  | Código del segundo programa (si aplica).                                                              |
| PROGRAMA_2                 | String  | Nombre del segundo programa (si aplica).                                                              |
| NIVEL_PROGRAMA_2           | String  | Nivel académico del segundo programa. Valores posibles: Pregrado, Magíster, etc.                      |
| DESCRIPCION_ESTADO_RETIRO  | String  | Descripción del tipo de retiro si aplica. Valores posibles: Retiro voluntario, Abandono, Grado.       |
| REINTEGRO_REINGRESO        | String  | Indica si el estudiante se reintegró o reingresó. Valores posibles: SI, NO.                           |
| ESTADO_ACADEMICO_INICIAL   | String  | Estado académico al inicio del periodo.                                                               |

*Continúa en la siguiente página*

Table 2 – *Continuación de la página anterior*

| Columna                          | Tipo   | Descripción                                                                 |
|----------------------------------|--------|-----------------------------------------------------------------------------|
| PERIODO_ESTADO_ACADEMICO_INICIAL | Int64  | Periodo del estado académico inicial.                                       |
| ESTADO_ACADEMICO_FINAL           | String | Estado académico al final del periodo.                                      |
| PERIODO_ESTADO_ACADEMICO_FINAL   | Int64  | Periodo del estado académico final.                                         |
| ENTRA_A_SUSPENSION               | String | Indica si entra a suspensión en el periodo. Valores posibles: SI, NO.       |
| ENTRA_A_PRUEBA_ACADEMICA         | String | Indica si entra a prueba académica en el periodo. Valores posibles: SI, NO. |
| SUSPENSIONES_ACUMULADAS          | Int64  | Número acumulado de suspensiones.                                           |
| PRUEBAS_ACADEMICAS_ACUMULADAS    | Int64  | Número acumulado de pruebas académicas.                                     |
| INCOMPLETOS_TOTALES_ACUMULADOS   | Int64  | Número acumulado de incompletos.                                            |

## A.2 Dataset 2: Historial Materias Estudiante

Table 3: Variables del Dataset: Historial Materias Estudiante

| Columna                     | Tipo   | Descripción                                                                                                                 |
|-----------------------------|--------|-----------------------------------------------------------------------------------------------------------------------------|
| CODIGO_ESTUDIANTE           | Int64  | Código estudiantil del estudiante. Todos los valores en esta columna tienen el formato: EST_XXXXXXXX.                       |
| CODIGO_CURSO                | String | Código del curso. Todos los valores en esta columna tienen el formato: CRS_XXXXXXXX.                                        |
| CRN                         | String | Course Reference Number, identificador único de sección. Todos los valores en esta columna tienen el formato: CRN_XXXXXXXX. |
| PERIODO                     | Int64  | Periodo académico como número de 6 dígitos (YYYYPP).                                                                        |
| NIVEL_ACADEMICO_ESTUDIANTE  | String | Nivel académico del estudiante al cursar la materia. Valores posibles: Pregrado, Posgrado.                                  |
| NUMERO_CREDITOS             | Int64  | Número de créditos de la materia.                                                                                           |
| SECCION                     | String | Sección específica del curso.                                                                                               |
| CODIGO_MODO_DE_CALIFICACION | String | Código del sistema de calificación aplicado. Valores posibles: N, AB, etc.                                                  |

*Continúa en la siguiente página*

Table 3 – *Continuación de la página anterior*

| Columna              | Tipo    | Descripción                                                                     |
|----------------------|---------|---------------------------------------------------------------------------------|
| CALIFICACION_PARCIAL | Decimal | Calificación parcial obtenida en el curso.                                      |
| CALIFICACION_FINAL   | Decimal | Calificación final obtenida en el curso.                                        |
| ESTATUS              | String  | Estado de la materia.                                                           |
| ATRIBUTOS            | String  | Atributos especiales del curso.                                                 |
| CODIGO_CAMPUS        | String  | Código del campus donde se dictó el curso.                                      |
| RESULTADO            | String  | Resultado final de la materia. Valores posibles: Aprobado, Reprobado, Retirado. |
| ES_HISTORICO_ACTUAL  | String  | Indica si es parte del historial actual o antiguo. Valores posibles: SI, NO.    |

### A.3 Dataset 3: Historial Rendimiento Académico

Table 4: Variables del Dataset: Historial Rendimiento Académico

| Columna                       | Tipo    | Descripción                                                                                          |
|-------------------------------|---------|------------------------------------------------------------------------------------------------------|
| CODIGO_ESTUDIANTE             | Int64   | Código estudiantil del estudiante. Todos los valores en esta columna tienen el formato: EST_XXXXXXX. |
| PERIODO                       | Int64   | Periodo académico como número de 6 dígitos (YYYYPP).                                                 |
| PGA                           | Decimal | Promedio General Acumulado del estudiante.                                                           |
| PROMEDIO_SEMESTRAL            | Decimal | Promedio del semestre actual.                                                                        |
| CREDITOS_PGA                  | Int64   | Créditos que cuentan para el cálculo del PGA.                                                        |
| DESCRIPCION_NIVEL_PROGRAMA    | String  | Nivel académico del programa. Valores posibles: Pregrado, Magíster, Doctorado.                       |
| CREDITOS_APROBADOS            | Int64   | Total acumulado de créditos aprobados.                                                               |
| CREDITOS_REPROBADOS           | Int64   | Total acumulado de créditos reprobados.                                                              |
| CREDITOS_INCOMPLETOS          | Int64   | Total acumulado de créditos incompletos.                                                             |
| CREDITOS_RETIRADOS            | Int64   | Total acumulado de créditos retirados.                                                               |
| CREDITOS_PENDIENTES           | Int64   | Total acumulado de créditos pendientes.                                                              |
| CREDITOS_HOMOLOGADOS          | Int64   | Total acumulado de créditos homologados.                                                             |
| PORCENTAJE_CREDITOS_APROBADOS | Decimal | Porcentaje de créditos aprobados sobre el total.                                                     |

*Continúa en la siguiente página*

Table 4 – *Continuación de la página anterior*

| Columna                                | Tipo    | Descripción                                                               |
|----------------------------------------|---------|---------------------------------------------------------------------------|
| TOTAL_SEMESTRES_MATRICULADOS           | Int64   | Número de semestres matriculados.                                         |
| MATERIA_POR_TERCERA_VEZ                | String  | Indica si cursó alguna materia por tercera vez. Valores posibles: SI, NO. |
| CREDITOS_APROBADOS_SEMESTRE            | Int64   | Créditos aprobados en el semestre actual.                                 |
| CREDITOS_REPROBADOS_SEMESTRE           | Int64   | Créditos reprobados en el semestre actual.                                |
| CREDITOS_INCOMPLETOS_SEMESTRE          | Int64   | Créditos incompletos en el semestre actual.                               |
| CREDITOS_RETIRADOS_SEMESTRE            | Int64   | Créditos retirados en el semestre actual.                                 |
| CREDITOS_PENDIENTES_SEMESTRE           | Int64   | Créditos pendientes en el semestre actual.                                |
| CREDITOS_HOMOLOGADOS_SEMESTRE          | Int64   | Créditos homologados en el semestre actual.                               |
| PORCENTAJE_CREDITOS_APROBADOS_SEMESTRE | Decimal | Porcentaje de créditos aprobados en el semestre.                          |

#### A.4 Dataset 4: Información Actual Estudiante

Table 5: Variables del Dataset: Información Actual Estudiante

| Columna                    | Tipo   | Descripción                                                                                           |
|----------------------------|--------|-------------------------------------------------------------------------------------------------------|
| CODIGO_ESTUDIANTE          | Int64  | Código estudiantil del estudiante. Todos los valores en esta columna tienen el formato: EST_XXXXXXXX. |
| PERIODO                    | Int64  | Periodo académico más reciente.                                                                       |
| EDAD                       | Int64  | Edad del estudiante en años.                                                                          |
| GENERO                     | String | Género del estudiante. Todos los valores en esta columna tienen el formato: A, B u OTRO.              |
| CODIGO_FACULTAD_PROGRAMA_1 | String | Código de la facultad del primer programa.                                                            |

*Continúa en la siguiente página*

Table 5 – *Continuación de la página anterior*

| Columna                     | Tipo    | Descripción                                                                                         |
|-----------------------------|---------|-----------------------------------------------------------------------------------------------------|
| CODIGO_PROGRAMA_1           | String  | Código del primer programa.                                                                         |
| PROGRAMA_1                  | String  | Nombre del primer programa.                                                                         |
| NIVEL_PROGRAMA_1            | String  | Nivel académico del primer programa. Valores posibles: Pregrado, Magíster, Doctorado.               |
| CODIGO_FACULTAD_PROGRAMA_2  | String  | Código de la facultad del segundo programa (si aplica).                                             |
| CODIGO_PROGRAMA_2           | String  | Código del segundo programa (si aplica).                                                            |
| PROGRAMA_2                  | String  | Nombre del segundo programa (si aplica).                                                            |
| NIVEL_PROGRAMA_2            | String  | Nivel académico del segundo programa. Valores posibles: Pregrado, Magíster, Doctorado.              |
| ESTADO_ACADEMICO            | String  | Estado académico actual del estudiante.                                                             |
| MATRICULADO_PERIODO_ACTUAL  | String  | Indica si está matriculado en el periodo actual. Valores posibles: SI, NO.                          |
| ULTIMO_PERIODO_MATRICULADO  | Int64   | Último periodo en el que estuvo matriculado.                                                        |
| PERIODO_CATALOGO            | Int64   | Periodo de catálogo académico aplicable.                                                            |
| PENALIZADO_EXTRACREDITACION | String  | Indica si tiene penalización por extracreditación. Valores posibles: SI, NO.                        |
| PENSUM_REFORMADO            | String  | Indica si está bajo pensum reformado. Valores posibles: SI, NO.                                     |
| PROMEDIO_MOVIL              | Decimal | Promedio móvil del estudiante.                                                                      |
| CREDITOS_MAXIMOS            | Int64   | Número máximo de créditos que puede inscribir.                                                      |
| NOMBRE_COLEGIO              | String  | Nombre del colegio de origen. Todos los valores en esta columna tienen el formato: SCH_XXXXXXX.     |
| CIUDAD_COLEGIO              | String  | Ciudad del colegio de origen.                                                                       |
| DEPARTAMENTO_COLEGIO        | String  | Departamento del colegio de origen.                                                                 |
| PUNTAJE_ICFES               | Decimal | Puntaje total ICFES/Saber 11.                                                                       |
| ICFES_CRITERIO_1            | Decimal | Puntaje en primer criterio de evaluación .                                                          |
| ICFES_CRITERIO_2            | Decimal | Puntaje en segundo criterio de evaluación .                                                         |
| ICFES_CRITERIO_3            | Decimal | Puntaje en tercer criterio de evaluación .                                                          |
| ICFES_CRITERIO_4            | Decimal | Puntaje en cuarto criterio de evaluación .                                                          |
| ICFES_CRITERIO_5            | Decimal | Puntaje en quinto criterio de evaluación.                                                           |
| ESTRATO_SOCIOECONOMICO      | String  | Estrato socioeconómico del estudiante. Todos los valores en esta columna tienen valores entre U y Z |

## A.5 Dataset 5: Horarios Curso



Table 6: Variables del Dataset: Horarios Curso

| Columna             | Tipo   | Descripción                                                                                                                |
|---------------------|--------|----------------------------------------------------------------------------------------------------------------------------|
| CRN                 | String | Course Reference Number, identificador único de sección. Todos los valores en esta columna tienen el formato: CRN_XXXXXXX. |
| CODIGO_CURSO        | String | Código del curso. Todos los valores en esta columna tienen el formato: CRS_XXXXXXX.                                        |
| PERIODO             | Int64  | Periodo académico como número de 6 dígitos (YYYYPP).                                                                       |
| SECCION             | String | Sección específica del curso.                                                                                              |
| FECHA_INICIO_FRANJA | Date   | Fecha de inicio de la franja horaria.                                                                                      |
| FECHA_FIN_FRANJA    | Date   | Fecha de finalización de la franja horaria.                                                                                |
| HORA_INICIO_FRANJA  | Time   | Hora de inicio de la franja horaria.                                                                                       |
| HORA_FIN_FRANJA     | Time   | Hora de finalización de la franja horaria.                                                                                 |
| CODIGO_SALON        | String | Código del salón donde se dicta el curso.                                                                                  |
| LUNES               | Int64  | Indica si hay clase los lunes. Valores posibles: 0, 1.                                                                     |
| MARTES              | Int64  | Indica si hay clase los martes. Valores posibles: 0, 1.                                                                    |
| MIERCOLES           | Int64  | Indica si hay clase los miércoles. Valores posibles: 0, 1.                                                                 |
| JUEVES              | Int64  | Indica si hay clase los jueves. Valores posibles: 0, 1.                                                                    |
| VIERNES             | Int64  | Indica si hay clase los viernes. Valores posibles: 0, 1.                                                                   |
| SABADO              | Int64  | Indica si hay clase los sábados. Valores posibles: 0, 1.                                                                   |
| DOMINGO             | Int64  | Indica si hay clase los domingos. Valores posibles: 0, 1.                                                                  |

## A.6 Dataset 6: Riesgos Estudiante Pregrado

Table 7: Variables del Dataset: Riesgos Estudiante Pregrado

| Columna                                   | Tipo  | Descripción                                                                                             |
|-------------------------------------------|-------|---------------------------------------------------------------------------------------------------------|
| CODIGO_ESTUDIANTE                         | Int64 | Código estudiantil del estudiante. Todos los valores en esta columna tienen el formato: EST_XXXXXXX.    |
| PERIODO                                   | Int64 | Periodo académico como número de 6 dígitos (YYYYPP).                                                    |
| tres_o_mas_materias_parcialmente_perdidas | Int64 | Indicador de riesgo: tres o más materias con calificación parcial reprobatoria. Valores posibles: 0, 1. |
| tres_o_mas_materias_retiradas             | Int64 | Indicador de riesgo: tres o más materias retiradas en el semestre. Valores posibles: 0, 1.              |
| bajo_promedio_segundo_semestre            | Int64 | Indicador de riesgo: promedio bajo en segundo semestre de carrera. Valores posibles: 0, 1.              |

*Continúa en la siguiente página*

Table 7 – *Continuación de la página anterior*

| Columna                                        | Tipo  | Descripción                                                                                                |
|------------------------------------------------|-------|------------------------------------------------------------------------------------------------------------|
| bajo_promedio_tercer_semestre_o_mas            | Int64 | Indicador de riesgo: promedio bajo desde tercer semestre en adelante. Valores posibles: 0, 1.              |
| bajo_promedio_movil                            | Int64 | Indicador de riesgo: promedio móvil por debajo del umbral. Valores posibles: 0, 1.                         |
| pocos_creditos_inscritos_para_matricula_pagada | Int64 | Indicador de riesgo: créditos inscritos significativamente menores a lo esperado. Valores posibles: 0, 1.  |
| materias_bloqueantes                           | Int64 | Indicador de riesgo: tiene materias bloqueantes sin aprobar. Valores posibles: 0, 1.                       |
| semestres_perdidos_con_estado_normal           | Int64 | Indicador de riesgo: semestres reprobados con estado académico normal. Valores posibles: 0, 1.             |
| no_lectura_ingles_sexto_semestre               | Int64 | Indicador de riesgo: no ha aprobado requisito de lectura/inglés al sexto semestre. Valores posibles: 0, 1. |
| porcentaje_creditos_aprobados_menor_50         | Int64 | Indicador de riesgo: menos del 50% de créditos inscritos aprobados. Valores posibles: 0, 1.                |

## A.7 Dataset 7: Información Financiera Estudiante

Table 8: Variables del Dataset: Información Financiera Estudiante

| Columna                                | Tipo    | Descripción                                                                                          |
|----------------------------------------|---------|------------------------------------------------------------------------------------------------------|
| CODIGO_ESTUDIANTE                      | Int64   | Código estudiantil del estudiante. Todos los valores en esta columna tienen el formato: EST_XXXXXXX. |
| PERIODO                                | Int64   | Periodo académico como número de 6 dígitos (YYYYPP).                                                 |
| TIPO_FINANCIAMIENTO_ESPECIFICO         | String  | Tipo detallado del financiamiento aplicado. Ejemplos: Beca ICETEX, Descuentos, etc.                  |
| FECHA_AFECTION                         | Date    | Fecha en que se aplicó el financiamiento.                                                            |
| TIPO_SECCION                           | String  | Tipo de sección financiera.                                                                          |
| OP_PRINCIPAL_PARCIAL                   | String  | Indica si es operación financiera principal o parcial. Valores posibles: Principal, Parcial.         |
| PORCENTAJE_APORTE_ITEM                 | Decimal | Porcentaje de aporte del ítem financiero.                                                            |
| RANKING                                | Int64   | Ranking del financiamiento (1=principal).                                                            |
| DESCRIPCION_NIVEL_PROGRAMA_1           | String  | Nivel académico del programa asociado. Valores posibles: Pregrado, Magíster, etc.                    |
| TIPO_FINANCIAMIENTO_PRINCIPAL_SEMESTRE | String  | Tipo de financiamiento principal del semestre.                                                       |
| TIPO_FINANCIAMIENTO_PRINCIPAL          | String  | Categoría general de financiamiento principal. Ejemplos: Beca, Crédito, Propio.                      |
| TIPO_MATRICULA_SEMESTRE                | String  | Tipo de matrícula del semestre.                                                                      |

## A.8 Dataset 8: Percentiles Académicos Estudiante

Table 9: Variables del Dataset: Percentiles Académicos Estudiante

| Columna                | Tipo    | Descripción                                                                                          |
|------------------------|---------|------------------------------------------------------------------------------------------------------|
| CODIGO_ESTUDIANTE      | Int64   | Código estudiantil del estudiante. Todos los valores en esta columna tienen el formato: EST_XXXXXXX. |
| PERIODO                | Int64   | Periodo académico como número de 6 dígitos (YYYYPP).                                                 |
| NIVEL_ACADEMICO        | String  | Nivel académico del programa. Valores posibles: Pregrado, Magíster, Doctorado.                       |
| CODIGO_PROGRAMA        | String  | Código del programa académico.                                                                       |
| PROGRAMA               | String  | Nombre del programa académico.                                                                       |
| PGA                    | Decimal | Promedio General Acumulado del estudiante.                                                           |
| PERCENTIL_PGA_PROGRAMA | Decimal | Percentil del PGA dentro del programa específico (0-100).                                            |
| TIPO_ESTUDIANTE        | String  | Clasificación del tipo de estudiante. Valores posibles: Regular, Transferencia, etc.                 |
| SEMESTRE_AVANCE        | Int64   | Semestre de avance curricular del estudiante.                                                        |
| GRUPO_SEMESTRES        | String  | Agrupación de estudiantes por rango de semestres. Ejemplos: 1-2, 3-4, 5-6.                           |
| NUMERO_PROGRAMA        | Int64   | Número de programa al que pertenece. Valores posibles: 1, 2.                                         |