

Resumen Ejecutivo

Sistema Inteligente de Consejería Académica

Introducción

Este documento sintetiza el proyecto de ciencia de datos para transformar la consejería académica universitaria mediante un sistema de agrupamiento jerárquico. El sistema permitirá fundamentar recomendaciones en evidencia empírica derivada de patrones históricos de desempeño estudiantil, abarcando desde la problemática hasta el análisis exploratorio que valida la viabilidad del sistema propuesto. Para análisis detallados, gráficas, distribuciones de variables y documentación exhaustiva, consultar los documentos complementarios: **Proyecto_CDA_Completo** que contiene una versión extendida de todo el análisis que se realizó aquí y **Exploracion_Datos_Completo** donde se encuentra a detalle la exploración de los datos.

1 Definición de la Problemática y Entendimiento del Negocio

La Universidad de los Andes atiende aproximadamente 14,000 estudiantes de pregrado distribuidos en más de 30 programas académicos. La consejería académica universitaria enfrenta desafíos por altas cantidades de estudiantes con perfiles diversos. Para el caso particular de la Universidad de Los Andes, esta diversidad incluye estudiantes de distintos programas, modalidades y condiciones académicas; lo que dificulta ofrecer un acompañamiento uniforme y oportuno. Los procesos actuales se sustentan principalmente en experiencia personal y criterio empírico de los consejeros, sin aprovechar datos históricos para identificar patrones de éxito o riesgo. Esta situación limita la consistencia, objetividad y personalización de las orientaciones, impactando tasas de graduación, deserción estudiantil y promedios académicos. La deserción es particularmente preocupante cuando podría haberse evitado con consejería académica adecuada. Las poblaciones afectadas son principalmente estudiantes (con dudas sobre carga académica y viabilidad de planes de estudio) y consejeros académicos (que orientan a cientos de estudiantes sin herramientas analíticas que respalden sus recomendaciones).

La solución propuesta incorpora una herramienta de ciencia de datos que agrupa estudiantes según patrones históricos de desempeño (cursos inscritos, promedios, secuencias de materias). Estos agrupamientos permitirán predecir cargas académicas viables y apoyar recomendaciones fundamentadas mediante análisis exploratorio y aprendizaje no supervisado, siguiendo enfoques exitosos implementados en sistemas de apoyo a consejería académica [Gutiérrez et al., 2020]. Aunque más adelante se va a describir en detalle esta metodología, en esta fase inicial también se considera importante obtener del stakeholder

un entendimiento cualitativo de los comportamientos históricos de ciertos KPIs críticos, como el tiempo promedio de consejería y la satisfacción del estudiante; para, luego, poder contrastarla con los resultados del análisis de datos. Por supuesto que la percepción actual de los stakeholders sobre KPIs es importante y valiosa, pero preferimos (como es la idea del proyecto) hacer un análisis lógico del histórico de estos mismos, solo para no caer en ideas y recuerdos únicamente.

El proyecto propone el desarrollo de un sistema de agrupamiento construido a partir de datos históricos de desempeño estudiantil. Este sistema buscará identificar patrones comunes entre estudiantes con trayectorias similares (cursos inscritos, en qué semestre, con qué promedio, secuencias de materias, etc.). Estos agrupamientos se usarán luego para predecir posibles cargas académicas futuras y apoyar a los consejeros con las recomendaciones.

Luego se va a explicar a mayor profundidad, pero el enfoque analítico inicial contempla la aplicación de técnicas de análisis exploratorio de datos y modelos de aprendizaje no supervisado, que permitan segmentar a los estudiantes en grupos de comportamientos académicos comparables.

Las métricas de desempeño (KPIs) que se van a usar para evaluar la efectividad del sistema se dividen en dos: a corto y largo plazo.

A corto plazo:

- **Tiempo promedio de consejería:** reducción del tiempo necesario para cada sesión gracias al acceso a información analítica fundamentada.
- **Nivel de satisfacción del estudiante:** percepción de los estudiantes respecto a la utilidad, claridad y personalización de esta nueva implementación.

Y, a largo plazo:

- **Promedio ponderado acumulado:** cambio del promedio en el rendimiento académico de los estudiantes luego de esta nueva implementación.
- **Tasa de aprobación de cursos:** proporción de estudiantes que aprueban materias con alta tasa de reprobación dentro de cada grupo identificado.

2 Diseño del Producto de Datos

El sistema tiene dos usuarios principales: consejeros académicos (usuarios primarios) que actualmente basan recomendaciones en revisión manual de carpetas y experiencia personal; y estudiantes (usuarios indirectos) que recibirán asesoría más confiable y personalizada.

El principal dolor es la naturaleza empírica del proceso actual, generando inconsistencias y uso ineficiente del tiempo. La oportunidad radica en proporcionar fundamentos objetivos basados en datos históricos de perfiles similares.

2.1 Requerimientos

El producto debe ser capaz de recuperar automáticamente el historial académico completo de un estudiante mediante su código de identificación y, a partir de una carga académica propuesta para el próximo semestre, posicionarlo dentro de un grupo de referencia mediante un algoritmo de agrupamiento multinivel (multilayer clustering). El sistema proporcionará una predicción de desempeño esperado junto con un índice de confianza que refleja la certeza de la clasificación realizada, permitiendo al consejero tomar decisiones informadas sobre la viabilidad del plan académico propuesto.

La recomendación surge del comportamiento histórico de estudiantes con perfiles comparables que tomaron combinaciones similares de materias. Para cada cluster, el sistema calcula el **porcentaje promedio de créditos aprobados** para estudiantes del cluster en semestres similares, estima la **probabilidad de aprobar todos los créditos** propuestos basándose en las características del estudiante y el historial del cluster, y presenta un **índice de confianza** que indica qué tan representativa es la muestra del cluster para ese caso particular.

Desde un punto de vista funcional, el sistema deberá cumplir con los siguientes requerimientos:

- El consejero ingresará el código del estudiante y el sistema cargará automáticamente su historial académico completo desde la base de datos institucional.
- El consejero definirá la carga académica propuesta para el próximo semestre y el modelo determinará el clúster de pertenencia más probable.
- El sistema calculará y presentará un índice de confianza que cuantifica la certeza de la agrupación, junto con predicciones de rendimiento esperado basadas en el comportamiento histórico del clúster identificado.
- Una aplicación web permitirá visualizar el perfil del estudiante, su clúster proyectado, el índice de confianza y las predicciones, además de explorar escenarios alternativos modificando la carga académica propuesta.
- El sistema almacenará las clasificaciones generadas y los resultados reales posteriores para validación y mejora continua del modelo.

El proyecto incluye dos componentes: analítico (identificar patrones mediante clustering) y tecnológico (aplicación web que integre el modelo para clasificar estudiantes y mostrar recomendaciones personalizadas).

En términos de integración al proceso actual de consejería, la herramienta funcionaría como un apoyo directo durante una sesión. El consejero puede ingresar la carga de materias propuesta al sistema y este le retorna la recomendación. Esta, entonces, es evaluada por el consejero y estudiante. Además, se contempla un **mecanismo de retroalimentación**, para que el consejero pueda ajustar o confirmar la recomendación según vea pertinente, capturando las razones de su decisión para mejora continua del modelo.

2.2 Componentes analíticos y tecnológicos

El proyecto se compone de dos partes principales. En el **componente analítico**, se emplearán datos históricos de expedientes estudiantiles para identificar patrones mediante técnicas de análisis exploratorio y algoritmos de agrupamiento (clustering), con el fin de crear un modelo capaz de clasificar estudiantes en grupos de desempeño similares. En el **componente tecnológico**, este modelo se integrará en una aplicación web que permitirá ingresar los datos de un estudiante, procesarlos a través del modelo entrenado y mostrar su grupo de pertenencia junto con recomendaciones académicas personalizadas.

El primer prototipo fue diseñado utilizando Figma y puede verse en el siguiente enlace: <https://www.figma.com/community/file/1563043270302634802>

3 Implicaciones Éticas

El análisis requiere considerar la Constitución Colombiana (Artículo 15) y la Ley 1581 de 2012 sobre protección de datos personales, exigiendo consentimiento previo, expreso e informado [y a Distancia (UNAD), 2025, ProtecData Latam, 2022]. La universidad cumple con estas obligaciones según su normatividad interna, garantizando la confidencialidad en el tratamiento de información académica [FEVAS, 2023]. Los datos académicos son sensibles y deben ser accesibles exclusivamente por personal autorizado.

Se aplicarán medidas contra reidentificación mediante técnicas de agregación, perturbación estadística, y supresión selectiva de datos [Archivo General de la Nación, 2021], junto con controles de acceso, encriptación y protocolos de seguridad robustos. Los modelos de machine learning pueden funcionar como cajas negras; siguiendo recomendaciones internacionales sobre el uso ético de la inteligencia artificial en educación [UNESCO, 2021], se garantizará transparencia algorítmica, documentación exhaustiva y auditorías periódicas para detectar sesgos algorítmicos [Área eLearning, 2024]. Los estudiantes serán informados proactivamente sobre clasificaciones asignadas, pudiendo cuestionarlas o refutarlas.

4 Enfoque Analítico

Las hipótesis principales establecen que existen segmentos claros de estudiantes con trayectorias similares para predecir riesgo o éxito académico; que las recomendaciones fundamentadas en el grupo de pertenencia pueden disminuir probabilidad de baja académica; y que la automatización parcial proporcionará orientación con fundamentos más sólidos.

Las preguntas de negocio buscan identificar características discriminantes (promedios, créditos, patrones de retiro, secuencias curriculares) y determinar la proporción de estudiantes correctamente agrupables en segmentos accionables.

Se adoptará el enfoque metodológico propuesto por Clarke [Clarke, 2008] y Ochoa et al. [Ochoa et al., 2016] para manejar estructuras jerárquicas en contextos educativos. Se implementará un modelo multinivel que capture variabilidad entre estudiantes individuales y entre programas académicos, adaptando dinámicamente la granularidad del clustering según densidad y distribución de datos.

El modelo se espera que funcione efectivamente incluso en escenarios con pocos datos, como estudiantes de segundo semestre, gracias a la arquitectura jerárquica del multilevel clustering: si existe suficiente densidad de muestras en el nivel específico, asigna un cluster detallado con predicciones precisas; si no, recurre automáticamente a un nivel de agregación superior proporcionando una estimación más general pero aún informativa; en casos extremos, usa el comportamiento promedio del programa como referencia base. El índice de confianza refleja apropiadamente la incertidumbre en cada predicción.

Es importante aclarar que **no se utilizan dos modelos separados**. El sistema funciona con un único modelo de clustering multinivel que agrupa estudiantes históricos según patrones de desempeño, asigna un nuevo estudiante al cluster apropiado y calcula probabilidades de éxito basándose en las métricas agregadas del cluster (porcentaje de créditos aprobados, tasas de aprobación histórica). La mención de métricas como AUC-ROC y AUC-PR se refiere a la evaluación de qué tan bien el clustering permite discriminar entre estudiantes de alto y bajo riesgo, comparando las predicciones derivadas de los clusters con resultados reales observados, pero no implican la existencia de un modelo supervisado adicional. El clustering no supervisado genera las agrupaciones, y las predicciones emergen naturalmente de las estadísticas agregadas de cada grupo.

Las métricas de evaluación incluyen: ganancia de ajuste multinivel vs. un nivel; homogeneidad interna de grupos; varianza entre niveles jerárquicos; estabilidad mediante bootstrapping; AUC-ROC y AUC-PR para discriminación derivada del clustering; Brier score y curvas de calibración para validar probabilidades predichas.

5 Recolección de Datos

El proyecto utiliza ocho datasets anonimizados del observatorio académico institucional con protocolo riguroso de pseudonimización, generalización y supresión selectiva. Los identificadores directos fueron sustituidos por códigos alfanuméricos únicos que mantienen consistencia relacional.

Los datasets principales incluyen: Historial Estados Estudiante (616,085 registros, trayectoria académica completa); Historial Materias Estudiante (4,931,740 registros, cada materia inscrita con créditos y calificaciones); Historial Rendimiento Académico (611,654 registros, indicadores como PGA y distribución de créditos); Información Actual Estudiante (222,407 registros, estado reciente con datos demográficos generalizados); Horarios Curso (444,834 registros, programación académica); Riesgos Estudiante Pregrado (369,370 registros, indicadores binarios de factores de riesgo); Información Financiera Estudiante (793,198 registros, modalidades de financiamiento); Percentiles Académicos Estudiante (158,429 registros, rendimiento relativo por programa). **Los diccionarios de datos completos se encuentran en los anexos del documento Proyecto_CDA_Completo.**

6 Entendimiento de los Datos

La calidad general es notablemente buena con menos del 1 % de nulos en variables críticas. Excepciones: variables de segundo programa (¿80 % nulos, se descartarán), información pre-universitaria (35-66 % nulos, uso limitado), indicadores de riesgo (nulos por diseño

representan ausencia de riesgo). Se detectaron valores atípicos: edad máxima de 1935 años y créditos máximos de un millón, requiriendo limpieza.

Variables críticas identificadas en cuatro dimensiones: Capacidad académica (percentil PGA, PGA con media 3.97, porcentaje créditos aprobados 89.4 %, promedio semestral); Experiencia y progreso (semestre estimado, grupo de semestres, total semestres matriculados media 4.84, créditos acumulados); Indicadores de riesgo (créditos reprobados/retirados, tres o más materias retiradas ~ 5 %, estado académico, materias por tercera vez); Contexto del estudiante (programa y nivel, tipo de matrícula, límite de créditos, estrato socioeconómico).

Del Historial de Materias emergen hallazgos relevantes: media de créditos por materia 2.77 (mediana 3.0); posibilidad de analizar redes de co-inscripción y secuencias curriculares exitosas vs. problemáticas. Del dataset de Riesgos: 15 % presenta tasa de aprobación ≥ 50 % (riesgo extremo); 52.55 % no cumple requisito de lectura/inglés al sexto semestre. El percentil de PGA por programa emerge como variable estrella al normalizar contextualmente el rendimiento.

La integración usará código de estudiante como llave primaria, partiendo de información actual y enriqueciéndola progresivamente con historial de rendimiento, percentiles, riesgos, estados académicos, información financiera, historiales de materias y horarios para validar factibilidad práctica.

Para análisis exhaustivo del entendimiento de los datos, incluyendo todas las gráficas, distribuciones detalladas de variables y análisis estadísticos profundos, consultar el documento complementario **Exploracion Datos Completo**, donde se revisa cada producto de datos a profundidad.

7 Preparación de Datos

El proceso de preparación inició con cinco conjuntos de datos en formato Parquet: historial de materias, rendimiento académico, percentiles, información actual de estudiantes y riesgos históricos. La transformación se estructuró en cuatro fases principales:

Limpieza y estandarización: Se filtraron registros de pregrado con historial completo, excluyendo estados “en progreso”. Los resultados académicos se estandarizaron en APROBADO (codificado como 1), REPROBADO y RETIRADO (codificados como 0), creando la variable binaria EXITO para calcular tasas de éxito mediante agregaciones.

Tratamiento de valores faltantes: Para el rendimiento académico (PGA), cuando no existe PGA previo se utilizó el puntaje ICFES normalizado mediante $(ICFES/500) \times 5$. Los registros sin ninguna de estas fuentes fueron excluidos. Variables de percentiles y riesgos conservaron nulos o se imputaron con cero según su interpretación semántica.

Ingeniería de características jerárquicas: Se diseñó un sistema de tres niveles para representar combinaciones de cursos: NIVEL_1 utiliza el número total de cursos; NIVEL_2 agrupa por categoría temática (primeros tres dígitos del código); NIVEL_3 usa códigos exactos ordenados alfabéticamente. Esta jerarquía permite balancear cobertura y especificidad según disponibilidad de datos.

Variables históricas y agregación temporal: Se calculó PGA_ANTERIOR usando merge_asof

con dirección *backward* para evitar *data leakage*. Se agregaron datos al nivel semestre generando: lista de cursos, créditos totales, número de cursos y tasa de éxito. Las variables continuas fueron normalizadas con `StandardScaler` entrenado exclusivamente sobre el conjunto de entrenamiento.

El pipeline procesó aproximadamente 285.000 registros generando un dataset final con 11 características principales y tres niveles jerárquicos.

8 Estrategia de Validación y Selección de Modelo

La validación se fundamentó en separación temporal estricta con tres conjuntos disjuntos:

- **Entrenamiento (TRAIN):** Períodos ≤ 202010 (~285.000 registros). Usado para construcción de clústeres mediante algoritmos de agrupamiento y cálculo de probabilidades por grupo.
- **Validación (VALIDATION):** Períodos entre 202011 y 202310 (~90.000 registros). Empleado para selección de hiperparámetros y evaluación en datos no vistos.
- **Prueba (TEST):** Períodos > 202310 (~72,253 registros). Reservado para evaluación final del modelo seleccionado.

Se verificó mediante prueba de Kolmogorov-Smirnov que la distribución de `TASA_EXITO` se conserva: TRAIN (media=0.874, std=0.203), VALIDATION (media=0.881) y TEST (media=0.885), confirmando que la partición temporal no introduce sesgos distribucionales. Las variables predictoras principales también mantienen distribuciones estables entre conjuntos.

9 Construcción y Evaluación del Modelo

Se experimentó con tres algoritmos de clustering: Fuzzy C-means, K-means y Gaussian Mixture Models (GMM), evaluando distintas configuraciones de hiperparámetros mediante Random Search con 10 iteraciones por algoritmo sobre las combinaciones de `NIVEL_1`. La evaluación cuantitativa sobre VALIDATION utilizó Mean Absolute Error (MAE) como métrica principal, complementada con métricas de estructura interna (Silhouette, Davies-Bouldin) para seleccionar el algoritmo final.

Cuadro 1: Comparación de algoritmos de clustering

Algoritmo	MAE	Silhouette	Davies-Bouldin
Fuzzy C-means	0.0679	0.3900	1.0616
GMM	0.0675	0.2948	1.5107
K-means	0.0680	0.3924	1.0561

Aunque GMM presenta el menor MAE, **Fuzzy C-means fue seleccionado como modelo final** por tres razones: (1) equilibrio entre precisión y separación estructural de clústeres; (2) costo computacional significativamente menor, crítico para aplicación interactiva; (3) modelado realista de transición continua entre niveles de rendimiento mediante

pertenencia difusa, consistente con la naturaleza no discreta del comportamiento estudiantil. Este algoritmo se aplicó consistentemente a través de los tres niveles jerárquicos (NIVEL_1, NIVEL_2, NIVEL_3).

Cualitativamente, el modelo genera clústeres interpretables con diferenciación clara entre perfiles de alto, medio y bajo rendimiento. Como oportunidades de mejora se identificaron: incorporación de variables socioeconómicas, análisis de trayectorias longitudinales más extensas e integración de señales tempranas de riesgo.

10 Construcción del Producto de Datos

A partir del modelo seleccionado se desarrolló un prototipo funcional del sistema LADA que integra:

Funcionalidad principal: El sistema permite ingresar el código del estudiante y una configuración hipotética de cursos, retornando la probabilidad estimada de éxito académico, información del clúster asignado, nivel de análisis utilizado, índice de confianza y características agregadas del grupo de referencia.

Arquitectura: La solución contempla un backend para procesamiento e inferencia, un frontend como dashboard interactivo y despliegue sobre infraestructura local institucional. Esta arquitectura desacoplada facilita escalabilidad y mantenimiento.




Figura 1: Arquitectura de despliegue del sistema LADA

Interfaz de usuario: Los consejeros pueden ingresar el código del estudiante, construir la carga académica propuesta controlando el límite de créditos y obtener la predicción en tiempo real. El resultado incluye el porcentaje de éxito estimado acompañado de visualizaciones detalladas del clúster asignado: distribuciones de GPA histórico, semestres cursados y porcentaje de créditos aprobados, destacando la posición del estudiante frente a su cohorte comparable.

Despliegue y monitoreo: En el estado TO-BE se plantea una arquitectura modular basada en *stateless serving* mediante API REST para predicciones *online*. El despliegue utilizará contenedores Docker para portabilidad. Se implementará monitoreo de *data drift* y *concept drift* mediante: (1) seguimiento periódico de métricas de consistencia; (2) entrenamiento de mini-modelo auxiliar con datos recientes (últimos dos años) para detectar cambios significativos; (3) protocolo de revisión activado cuando se detecten desviaciones seguidas en métricas.

El sistema fue validado cualitativamente por miembros de la organización, confirmando su utilidad como herramienta de apoyo para planeación de carga, consejería y acompañamiento estudiantil. Puede encontrarse el funcionamiento de la aplicación en el siguiente link https://www.youtube.com/watch?v=wS177DZ9_Kw

11 Retroalimentación de la Organización

11.1 Primera interacción: Definición del alcance

El acercamiento inicial con la unidad de ingeniería estableció el enfoque en consejería académica (sobre deserción estudiantil). Se acordó el acceso a datos bajo estrictas condiciones de confidencialidad: información completamente anonimizada con ocultamiento de atributos identificables.

11.2 Segunda interacción: Anonimización y enfoque analítico

Se profundizó en el tratamiento de información: anonimización extendida a estudiantes, cursos, programas y campos institucionales. La organización conservó facultad de desanonimización interna para análisis detallado. Se formalizó el enfoque de *clustering multicapa* para analizar estudiantes desde distintos niveles de agregación.

11.3 Tercera interacción: Primer prototipo

Se presentó interfaz básica con funcionalidad de ingreso de código estudiantil y cursos. Las observaciones clave incluyeron: necesidad de explicar significado de clústeres (no solo ID numérico), diferenciar claramente “estudiantes similares” vs. “casos similares”, explicar niveles de análisis, cambiar restricción de número de cursos a cantidad de créditos, e incorporar variables descriptivas de cada clúster (porcentaje de créditos aprobados, semestres cursados, distribución de PGA).

11.4 Cuarta interacción: Validación de mejoras

La versión ajustada incorporó elementos de explicabilidad, gráficas descriptivas de clústeres, definición clara de niveles de análisis e índice de confianza. El representante organizacional validó positivamente la claridad de visualización y utilidad del sistema. Se programó socialización ampliada posterior a esta entrega para presentar resultados finales y evaluar escenarios de implementación futura.

12 Conclusiones

El proyecto cumplió con los objetivos propuestos, demostrando la viabilidad técnica y conceptual de un sistema inteligente de apoyo a la consejería académica de la Universidad de Los Andes basado en agrupamiento multinivel. Este avance representa un cambio claro desde un proceso actualmente empírico hacia uno que usa evidencia histórica y algoritmos lógicos que dan mayor validez a razonamientos.

Durante el desarrollo hubo varias dificultades a resaltar. La primera fue la necesidad de anonimizar los datos: dado que la información utilizada correspondía a estudiantes reales, no resultaba responsable emplearla sin un tratamiento previo que garantizara la protección de la identidad. Por esta razón, se implementaron múltiples técnicas de transformación y codificación tanto para estudiantes como para materias, asegurando la conservación de las relaciones estructurales sin exponer información sensible.

Segundo, y quizá el reto técnico más importante, la implementación de la estructura del modelo presentó múltiples dificultades. La complejidad de la arquitectura multicapa, junto con la necesidad de evitar completamente el uso de información futura durante el entrenamiento, obligó a diseñar cuidadosamente los procesos de agregación temporal, generación de variables históricas y validaciones automáticas de integridad temporal para prevenir *data leakage*.

Adicionalmente, el tratamiento de valores faltantes representó un desafío relevante, pues fue necesario combinar múltiples fuentes de información académica, como PGA e ICFES, para preservar la mayor cantidad posible de registros útiles sin introducir sesgos. Finalmente, la construcción de características jerárquicas para representar la carga académica implicó un balance constante entre nivel de detalle y cobertura de datos históricos, lo cual influyó directamente en la estabilidad del modelo y en su capacidad de generalización.

En relación al impacto sobre los KPIs mencionados durante el desarrollo del proyecto, se proyectan beneficios a corto y largo plazo. Por un lado, se anticipa una reducción del tiempo promedio de consejería entre un 25 % y 30 %, dado que los consejeros tendrían acceso inmediato a la predicción de agrupamiento y la decisión de recomendación puede empezar desde ahí durante la sesión. De manera complementaria, la satisfacción del estudiante podría aumentar entre 5 % y 12 % que se puede ver reflejado en encuestas posteriores a la sesión, debido a las recomendaciones más personalizadas y justificadas. Además, a largo plazo, se espera que el sistema contribuya a un aumento del 3 % al 5 % en el promedio ponderado acumulado de los estudiantes que usaron la herramienta durante la sesión de consejería un semestre tras otro. Del mismo modo, un aumento similar se proyecta para la tasa de aprobación de cursos con alta reprobación, al sugerir combinaciones de materias más coherentes con trayectorias históricas exitosas dentro de cada clúster. Por último, se espera una reducción de tasa de deserción en un 10 %. Por supuesto, estas cifras son estimaciones y deben validarse usando algún piloto institucional que dure un par de semestres, para tener una muestra de resultados completa.

Para alcanzar mejores resultados que los obtenidos en este proyecto, se buscaría un dataset con datos más extensos y menos sesgados. Por el lado del modelo, este mismo puede implementarse de forma más completa y robusta; integrando mayor cantidad de atributos que se tendrán en cuenta durante el agrupamiento.

Finalmente, aún cuando el mejor modelo obtenido es suficiente para dar una solución

inicial y sólida a la problemática propuesta, no debe interpretarse como la iteración final del mismo. El modelo actual funciona como una base avanzada y estable para un piloto, pero su rendimiento a largo plazo va a depender del proceso de monitorio continuo y la retroalimentación de los consejeros. Con estas iteraciones, el sistema tiene el potencial de convertirse en una herramienta institucional robusta capaz de transformar estructuralmente el proceso de consejería académica en la Universidad de Los Andes.

Referencias

- [Archivo General de la Nación, 2021] Archivo General de la Nación (2021). Guía de anonimización de datos estructurados. https://www.archivogeneral.gov.co/sites/default/files/Estructura_Web/5_Consulte/Recursos/Publicaciones/Guia_de_Anonimizacion-min.pdf. Ministerio de Cultura.
- [Clarke, 2008] Clarke, P. (2008). When can group level clustering be ignored? multilevel models versus single-level models with sparse data. *Journal of Epidemiology and Community Health*, 62(8):752–758.
- [FEVAS, 2023] FEVAS (2023). Guía: La confidencialidad en el ámbito educativo. <https://fevas.org/wp-content/uploads/2023/04/GUIA-LA-CONFIDENCIALIDAD-EN-EL-AMBITO-EDUCATIVO.pdf>.
- [Gutiérrez et al., 2020] Gutiérrez, F., Ochoa, X., Chiliza, K., and De Laet, T. (2020). Lada: A learning analytics dashboard for academic advising. *Computers in Human Behavior*, 107:105826.
- [Ochoa et al., 2016] Ochoa, X., Méndez, G., Chiliza, K., and Luzardo, G. (2016). Adaptive multilevel clustering model for the prediction of academic risk. In *Proceedings of the 6th International Conference on Learning Analytics & Knowledge (LAK '16)*, pages 237–241, Edinburgh, United Kingdom. ACM.
- [ProtecData Latam, 2022] ProtecData Latam (2022). Concepto sector educación sobre tratamiento de datos personales. <https://protecdatalatam.com/wp-content/uploads/2022/03/CONCEPTO-SECTOR-EDUCACION.pdf>.
- [UNESCO, 2021] UNESCO (2021). El uso ético de la inteligencia artificial en la educación. <https://unac.edu.mx/blog-2/el-uso-etico-de-la-inteligencia-artificial-en-la-educacion/>. Universidad de las Américas y el Caribe.
- [y a Distancia (UNAD), 2025] y a Distancia (UNAD), U. N. A. (2025). Lo que debes saber sobre el tratamiento y protección de datos personales. <https://noticias.unad.edu.co/index.php/2025/7277-lo-que-debes-saber-sobre-el-tratamiento-y-proteccion-de-datos-personales>. Noticias UNAD.
- [Área eLearning, 2024] Área eLearning (2024). Ética y sesgos en ia educativa: retos y soluciones. <https://areaelearning.com/etica-y-sesgos-en-ia-educativa-retos-y-soluciones/>.